

Relazione Attività 3 CFU : Segmentazione con Clustering di Dati di Imaging da Spettrometria di Massa

Biagio Spiezia

27 gennaio 2026

L'obiettivo del presente lavoro è lo sviluppo di una pipeline in linguaggio R per l'analisi e l'integrazione di dati MALDI-MSI multi-layer (lipidi, peptidi e glicani). Il focus principale risiede nella creazione di una strategia capace di gestire diverse risoluzioni spaziali, ottimizzare la riduzione della dimensionalità tramite PCA e validare la qualità del clustering attraverso metriche di coerenza spaziale e similarità cross-omica.

La funzione di base integra tre diverse strategie di selezione:

- **Criterio di Kaiser:** Selezione basata su autovalori > 1 .
- **Percentuale di Varianza:** Selezione del numero di PC necessario a coprire l'80% della varianza.
- **Metodo Elbow:** Implementazione di un calcolo geometrico per individuare il "punto di gomito" nella curva degli autovalori.

Sebbene la pipeline implementi tre diverse strategie di selezione delle nPC , il metodo **Elbow** è stato identificato come il più robusto per l'analisi del segnale MALDI-MSI.

- **Limite del Criterio di Kaiser:** Dai test effettuati, il criterio di Kaiser ha mostrato una forte tendenza a selezionare tante componenti all'aumentare della risoluzione (passando da 9 PC alla risoluzione di 50, a 27 alla risoluzione di 150). Molti autovalori superano la soglia di 1 includendo tante componenti.
- **Limite della Varianza (80%):** Questo criterio è risultato troppo semplicistico per i dati, spesso selezionando un numero di componenti insufficiente (1 o 2) per descrivere la complessità chimica del tessuto, portando a valori di spARI estremamente bassi.
- **Efficacia del Metodo Elbow:** Il calcolo geometrico del "gomito" ha permesso di isolare il punto in cui l'aggiunta di una componente ulteriore non apporta più un guadagno informativo significativo. Per tutte le risoluzioni, l'Elbow ha mantenuto una selezione stabile di 3-4 componenti. Questo numero ridotto si è dimostrato essere il nucleo informativo: è sufficientemente piccolo da filtrare il rumore, ma sufficientemente rappresentativo da mantenere intatta la struttura spaziale del tessuto, come confermato dai valori maggiori di spARI ottenuti.

0.1 Riduzione della Dimensionalità (PCA)

Data l'alta dimensionalità dei dati MSI, caratterizzati da migliaia di canali m/z per ogni pixel, l'applicazione della PCA è stata implementata non solo per l'efficienza computazionale, ma come fondamentale strumento di estrazione delle feature.

0.2 Validazione Spaziale: spARI

Per valutare se la riduzione dei dati ha mantenuto la coerenza biologica, è stato utilizzato l'indice spARI (Spatial Adjusted Rand Index). Questa metrica valida la qualità del clustering verificando la continuità spaziale delle etichette:

$$spARI = \frac{1}{N \cdot k} \sum_{i=1}^N \sum_{j \in \mathcal{N}_k(i)} I(L_i = L_j) \quad (1)$$

dove L rappresenta l'etichetta del cluster e $\mathcal{N}_k$ l'intorno spaziale del pixel ($k = 5$).

1 Risultati

1.1 Analisi dei singoli Dataset

I risultati mostrano che lo spARI migliora progressivamente con l'aumentare della risoluzione dell'immagine.

Tabella 1: Risultati spARI (Metodo Elbow) per risoluzione

Risoluzione	Lipids	Peptides	Glycans
50	0.329	0.381	0.411
100	0.375	0.314	0.531
150	0.501	0.390	0.514

2 Integrazione Multi-omica

L'integrazione è stata realizzata tramite *PC1 Fusion*. Nonostante il limitato numero di pixel comuni ($n = 35$), lo spARI dell'integrazione mostra un trend crescente con la risoluzione.

Tabella 2: Performance Integrazione Multi-omica

Risoluzione	Pixel Comuni	spARI Multi-Omico
50	35	0.189
100	35	0.251
150	35	0.263

3 Discussione e Sviluppi Futuri

Per consolidare i risultati della pipeline sviluppata, potrebbero essere implementate ulteriori strategie di validazione e miglioramento:

- **Image Registration:** L'integrazione risente del basso numero di pixel comuni. L'aggiunta di una funzione di allineamento spaziale (registration) permetterebbe di aumentare la dimensione del campione comune, rendendo le metriche ARI/NMI statisticamente più robuste.
- **Modelli Spaziali:** L'integrazione di modelli *Hidden Markov Random Fields* (HMRF) potrebbe forzare ulteriormente la coerenza spaziale in fase di clustering, aumentando potenzialmente i valori di spARI.
- **Ottimizzazione del Numero di Cluster:** Una prova cruciale consisterebbe nel variare il numero di componenti del clustering (G). Attualmente fissato a 5, il numero ottimale di cluster potrebbe essere identificato tramite criteri d'informazione come il *Bayesian Information Criterion* (BIC).
- **Analisi della Stabilità:** Sarebbe opportuno effettuare prove di *bootstrapping* per verificare quanto la selezione delle PC influenzi la stabilità dei cluster finali.